



**Universidad Tecnológica Centroamericana
UNITEC**

Proyecto Integrador

Presentado por:

Hailton Amaya 22211089

Felix Dominguez 12141043

Presentado a:

Kevin Eduardo Funez Funez

Clase y sección:

Fundamentos de Ciencia de Datos 1413

Carrera:

Ciencia de Datos e Inteligencia Artificial

Fecha:

26 de Junio de 2025

Ciudad:

Tegucigalpa M.D.C

Tabla de Contenido

Introducción.....	2
Objetivo General	3
Objetivos Específicos.....	3
Desarrollo	4
EDA	4
Limpieza de Datos	6
Modelo.....	8
Conclusiones.....	10
Bibliografía	12

Introducción

La ciencia de datos, es una herramienta de gran valor para las diferentes empresas del mundo, por la valiosa información que son capaces de extraer de los datos que estos van almacenando. Esta información se traduce directamente en resultados que ayudan a las empresas a generar más ingresos al generar estrategias a base de esos conocimientos. Los diferentes métodos de predicción son muy útiles para esto, desde regresión lineal a series de tiempo. Una de las que más se utiliza hoy en día es la de la regresión logística, la cual se utiliza en la mayoría de casos para lograr predecir entre un sí o no dentro del negocio de la empresa, que puede tomar muchas formas. En este caso miraremos a una empresa de servicios de telecomunicación, para poder predecir si los clientes de esta dejan a la empresa o no, para de esta manera poder comprender porque se van, mejorando los ingresos de la empresa

Objetivo General

- Comprender las razones principales por las cuales los clientes de esta empresa se fugan, para poder hacer un modelo de predicción a base de ello.

Objetivos Específicos

- Visualizar el dataset inicial, para poder hacer observaciones y sacar insights de este
- Aplicar estos insights, sí son importantes dentro de la creación del modelo
- Comparar diferentes modelos y estrategias para poder ver cual de estos es el mejor

Desarrollo

EDA

El Análisis Exploratorio de Datos se llevó a cabo con el objetivo de comprender la distribución de las variables, identificar patrones, relaciones y posibles anomalías antes de la fase de modelado.

Métricas del Dataset:

- El dataset contiene un total de 7,041 registros, lo que proporciona una base de datos sustancial para el análisis y modelado.
- El max de TotalCharges es de 8,684.8 y el min es de 18.8. Esto indica un amplio rango de cargos totales entre los clientes, reflejando diferentes niveles de consumo de servicios y antigüedad.
- Existe la columna churn, la cual toma valores de 'Yes' y 'No', indicando las personas que cancelaron sus servicios, en el dataset existen 1,869 que sí abandonaron el servicio y 5,171 que no lo abandonaron.

Análisis de la Distribución de Clientes por Género y Relación:

- El gráfico de Gender muestra una distribución casi perfectamente equitativa entre hombres y mujeres, con un 50.4% de clientes masculinos y un 49.5% de clientes femeninos. Esto sugiere que el género por sí solo no es un factor determinante en la composición general de la base de clientes.
- La distribución de la variable Partner(pareja) indica que un 51.7% de los clientes tienen pareja, mientras que un 48.3% no la tienen. Al igual que el género, esta variable presenta una división relativamente balanceada.

Impacto de Servicios Adicionales en TotalCharges:

- Los gráficos de barras que muestran "Máx. de TotalCharges por DeviceProtection", "Máx. de TotalCharges por InternetService" y "Máx. de TotalCharges por Contract" revelan cómo los diferentes servicios y tipos de contrato se relacionan con los cargos totales.
- Los clientes con DeviceProtection tienden a acumular TotalCharges máximos significativamente más altos que aquellos sin este servicio o sin servicio de internet.
- Los clientes con Fibra óptica presentan los TotalCharges máximos más elevados, seguidos por DSL. Aquellos sin servicio de internet tienen cargos totales máximos considerablemente menores, lo cual es esperable ya que los servicios de internet suelen ser un componente importante del cobro mensual.
- Los contratos de dos años y un año están asociados con TotalCharges máximos más altos en comparación con los contratos mes a mes. Esto es lógico, ya que los contratos a más largo plazo implican una mayor permanencia y, por ende, acumulan más cargos totales a lo largo del tiempo.

Análisis de la distribución y relación con TotalCharges de servicios específicos:

- El gráfico de pastel "Recuento de Device Protection" indica que el 33.98% de los clientes tienen protección de dispositivo, el 21.66% no la tienen y un 43.9% no tienen servicio de internet (lo que implica que no pueden tener protección de dispositivo). Es relevante notar la gran porción de clientes sin internet, y por ende, sin este servicio asociado.
- La mayoría de los clientes(55.04%) tienen un contrato mes a mes, seguido por contratos de dos años(24.0%) y un año(20.92%). Esta alta proporción de contratos mes a mes es un factor de riesgo significativo para el churn, ya que estos clientes tienen menos compromiso a largo plazo y pueden cambiar de proveedor más fácilmente.

Relación entre tenure, MonthlyCharges y TotalCharges:

- Estas se muestran en los gráficos de dispersión, en "Máx. de MonthlyCharges por tenure": Se observa una tendencia creciente en los MonthlyCharges a medida que el tenure (antigüedad del cliente en meses) aumenta. Aunque hay dispersión, la nube de puntos sugiere que, en general, los clientes con más antigüedad tienden a tener cargos mensuales máximos más altos, lo que podría reflejar la adición de servicios a lo largo del tiempo o planes más costosos.
- "Máx. de TotalCharges por tenure": Existe una correlación lineal positiva y muy fuerte entre tenure y TotalCharges. Esto es completamente esperable, ya que TotalCharges representa la suma acumulada de los MonthlyCharges a lo largo del tenure del cliente. A mayor tiempo como cliente (tenure), mayores serán los cargos acumulados (TotalCharges).

Estos hallazgos guiarán la limpieza del dataset, selección de características y el diseño del modelo para predecir el Churn de los clientes.

Limpieza de Datos

Para limpieza de los datos se encontraron varias cosas que tomar en cuenta, Primero se vio que dentro de la columna TotalCharges habían 8 campos en blanco, los cuales se tuvieron que tratar de una forma distinta a los valores nulos. Estos se terminaron eliminando ya que solo formaban una parte minúscula del tamaño del dataset en general.

Después también para hacer el modelo se tuvieron que hacer dummies de varias columnas, aunque por medio de esto se aprendió que esta no era la mejor manera de transformar estas columnas. Hay 7 columnas las cuales tienen las opciones: Yes, No y una más que es en un caso No phone service y en el caso de las otras 6 No internet service. Estas dos opciones hacen referencia a la columna Phone service e Internet service, Phone service tenía las opciones Yes y No, mientras que Internet Service tenían las opciones Fiber

optic, DSL y No, las primeras dos haciendo referencia a que si tienen internet solo especificando el tipo y la otra directamente que no. Esto es muy importante ya que al hacer los dummies de todas las columnas con aquellas tres opciones, se podía ver que era obvio, que los dummies de No phone service y No internet service era lo opuesto a las columnas phone service e internet service, por ello tenían una multicolinealidad perfecta de 1 y por ello se tenían que quitar.

Aun así una vez solo tienen los diferentes dummies de Yes y No de todas estas columnas, el vif de cada uno de ellos era tan grande que python los tiraba como $\text{inf}(\text{infinito})$, y por ello también se tenían que quitar. Esto tenía sentido, ya que en la gran mayoría de veces cuando el dummy de yes era true, el de no era false y se predecían el uno al otro, solo con la excepción de cuando era no phone/internet service, en el cual ambas eran false. Por esto se dejó al lado usar dummies para estas columnas y en vez de ello lo que se hizo fue cambiar todos los no phone/internet service a no, ya que al fin y al cabo era cierto que ambos simplemente no tenían ese servicio, lo cual a la hora del modelo no afectaba mucho.

Una vez ya cambiadas todas estas a Yes o No, también junto a otras columnas que si desde el principio eran de Yes o No, se convirtieron a 1s y 0s, para que se pudiera utilizar dentro del modelo. Aun así al final si se utilizan las dummies para 3 otras columnas las cuales si tenían más de 2 valores y no terminaban de ser redundantes como el caso anterior. Aun así de todas estas siempre se tenía que eliminar una de estos dummies, ya que las otras dos o más dummies, la predecían, en la ausencia de todas las otras. Finalmente para el modelo, se terminaron quitando las variables de MonthlyCharges y TotalCharges, por sus altos valores de vif. También se cambió el nombre de algunas columnas para que tenga el mismo estilo de capitalización que las demás

Modelo

Una vez con los datos ya limpios se empezó con el modelo, el cual se podía intuir que era un caso de clasificación, y por ello se tenía que utilizar regresión logística. Esto se debe a que su nombre era TelcoClientes, que podíamos deducir que era un dataset de clientes de una empresa de telecomunicaciones, además de por el nombre de sus columnas. Por este nombre de columnas también se podía inferir la columna target que sería churn, que es un término en inglés que se usa mucho en las empresas, el cual se podría decir que es bastante sinónimo con regresión logística, además de que era un campo de 1s y 0s. Una vez identificado esto se tomó Churn como target y se tomaron el resto de variables para X, excepto CustomerID ya que era la única variable después de la limpieza que no se transformó en numérica. Después de esto se vieron los valores de la regresión OLS y también se tomaron las columnas con un p_value menor a 0.05. Después de ello se hizo la separación de datos para el entrenamiento y las pruebas y con esto se realizó el modelo de regresión logística.

Inicialmente al ver ambas la matriz de confusión y las estadísticas, estas no se veían muy convincentes, especialmente debido al objetivo de esta. Al fin y al cabo lo más importante para una empresa como esta de poder predecir, no es correctamente predecir si un cliente no se ha fugado, sino que predecir cuando un se fugó, para así saber porqué lo hizo y que se puede realizar para que no lo hagan futuros clientes. El modelo original podía predecir muy bien lo que no se fugaba, pero apenas podía predecir cuando se fugaban. Al revisarlo me di cuenta que esto podría ser debido a que en el dataset habian muchos mas clientes no fugados, que clientes fugados y esto podría estar sesgando la predicción. Por ello en la primera versión agregue dentro del llamado de la regresión lineal un parámetro llamado class_weight, a balanced, para este balanceara la carga y por medio de esto las métricas mejoraron mucho. Pero me salieron unas incluso mejores métricas al hacer un

resamplero utilizando smote(Sobremuestreo de minorías), debido al sesgo que había y por medio esto logre encontrar las mejores métricas con este dataset.

Conclusiones

El presente proyecto se centró en la aplicación de técnicas de Ciencia de Datos para comprender y predecir el fenómeno de la rotación de clientes (Churn) en una empresa de servicios de telecomunicaciones. A través de un análisis exhaustivo del dataset y la construcción de un modelo predictivo, se lograron los objetivos planteados.

En primer lugar, el Análisis Exploratorio de Datos (EDA) fue fundamental para obtener una visión clara de la composición del dataset y las relaciones entre las variables. Se identificó que la antigüedad del cliente y los TotalCharges tienen una correlación directa y fuerte, lo cual es predecible pero subraya la importancia del valor del ciclo de vida del cliente. De manera crucial, se observó que la mayoría de los clientes opta por contratos mes a mes, lo que representa un factor de riesgo significativo para el churn debido a la menor barrera de salida para estos clientes. Además, la distribución casi equitativa de variables como gender y Partner sugirió que, aunque presentes, su impacto individual en el churn podría ser menor en comparación con variables de servicio y contrato.

La fase de Limpieza de Datos fue determinante para preparar el dataset para el modelado. La detección y tratamiento de los 8 campos en blanco en TotalCharges (mediante eliminación, dado su pequeño porcentaje) fue un paso inicial importante. El desafío principal se encontró en el manejo de la multicolinealidad, especialmente en las columnas binarias (Yes/No/No phone service/No internet service) y entre MonthlyCharges y TotalCharges. La decisión de transformar las categorías "No phone service" y "No internet service" a "No" y posteriormente convertir las binarias a 1s y 0s, así como la eliminación de variables con altos valores de VIF como MonthlyCharges y TotalCharges, fueron pasos críticos para asegurar la robustez y la interpretabilidad del modelo de regresión logística.

Finalmente, la construcción del Modelo de Regresión Logística demostró la capacidad de predecir el churn. Se confirmó que el problema era de clasificación binaria, con Churn como la variable objetivo. Un hallazgo importante durante la modelación fue el desbalance de clases en el dataset (más clientes no fugados que fugados), lo que inicialmente sesgó las predicciones. La aplicación de la ponderación de clases y, de manera más efectiva, el sobremuestreo de la clase minoritaria mediante SMOTE, resultaron cruciales para mejorar significativamente la capacidad del modelo para identificar correctamente a los clientes que sí abandonan el servicio.

Bibliografía

Anshul. (s.f.). *Analytics Vidhya*. Obtenido de Regresión logística en el aprendizaje automático: <https://www.analyticsvidhya.com/blog/2021/08/conceptual-understanding-of-logistic-regression-for-data-science-beginners/>

IBM. (s.f.). *IBM*. Obtenido de Abandono de clientes en una empresa de telecomunicaciones: <https://www.ibm.com/docs/es/cognos-analytics/11.2.x?topic=samples-telco-customer-churn>

Kanade, V. (s.f.). *Spiceworks*. Obtenido de What Is Logistic Regression? Equation, Assumptions, Types, and Best Practices: <https://www.spiceworks.com/tech/artificial-intelligence/articles/what-is-logistic-regression/>

ONE.COM. (s.f.). *ONE.COM*. Obtenido de ¿Qué es el churn?: <https://www.one.com/es/tiendaonline/que-es-churn#:~:text=La%20traducci%C3%B3n%20de%20churn%20en,los%20negocios%20basados%20en%20suscripciones.>

Taylor, S. (s.f.). *CFI*. Obtenido de Regresión lineal múltiple: <https://corporatefinanceinstitute.com/resources/data-science/multiple-linear-regression/>

AWS. (s.f.). *¿Qué es la regresión logística?* Obtenido de Amazon AWS: <https://aws.amazon.com/es/what-is/logistic-regression/>

Compucima. (s.f.). *Qué son telecomunicaciones y su aplicación en las nuevas tecnologías de la información*. Obtenido de Compucima: <https://compucima.com.ec/que-son-telecomunicaciones/>

IBM. (16 de Agosto de 2021). *¿Qué es la regresión logística?* Obtenido de IBM:

<https://www.ibm.com/mx-es/think/topics/logistic-regression>

qualtricsXM. (s.f.). *Customer churn: cómo medir y prevenir la rotación de clientes.*

Obtenido de qualtrics: <https://www.qualtrics.com/es/gestion-de-la-experiencia/cliente/customer-churn/>

The Investopedia Team. (21 de Marzo de 2024). *Churn Rate: What It Means,*

Examples, and Calculations. Obtenido de Investopedia:

<https://www.investopedia.com/terms/c/churnrate.asp>